



Image Dehaze

From Dark Channel Prior to Prior Learning





CONTENTS

1

Hazy Image Model

2

Dark Channel Prior

3

Dehazing energy model

4

Proximal Dehaze-Net



Hazy Image Model




● Application



去雾的应用:

1. 驾驶辅助系统
2. 视频监控与安防
3. 摄影和电影制作

Dehazing Method



传统方法

对比度增强
独立主成分分析
暗通道

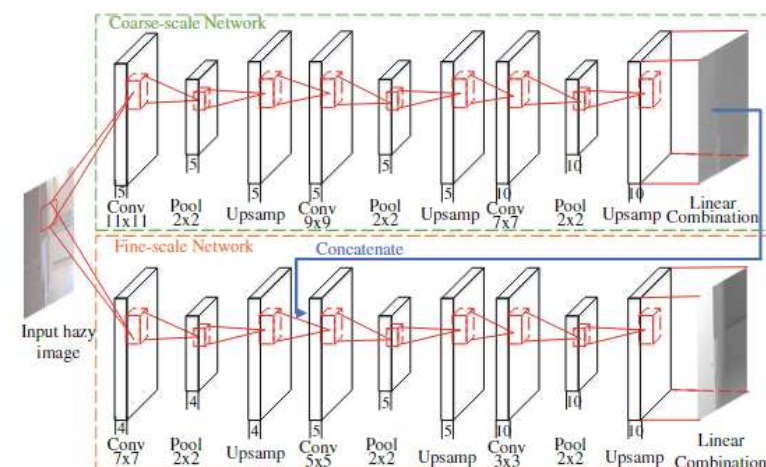
缺点:

1. 参数敏感性
2. 局限性
3. 计算复杂性


基于学习的方法^[1]

缺点:

1. 真实数据难以获取
2. 真实场景泛化性差



Haze Image Model



有雾图像 I



传输图像 T



去雾图像 J

有雾图像 I 建模为 Direct Transmission 和 Airlight (大气散射光) 的线性组合:

$$I(x) = J(x)T(x) + A(1 - T(x)) \quad \longrightarrow \quad J = \frac{I - A}{T} + A$$

- I : 有雾图像
- J : 无雾图像
- $T(x) = e^{-\beta(\lambda)d(x)}$: 传输图像, 表示目标反射光中经衰减后达到相机的比例
- A : 无穷远处的大气光值

02

Dark Channel Prior





Single Image Haze Removal Using Dark Channel Prior

Kaiming He¹

¹Department of Information Engineering
The Chinese University of Hong Kong

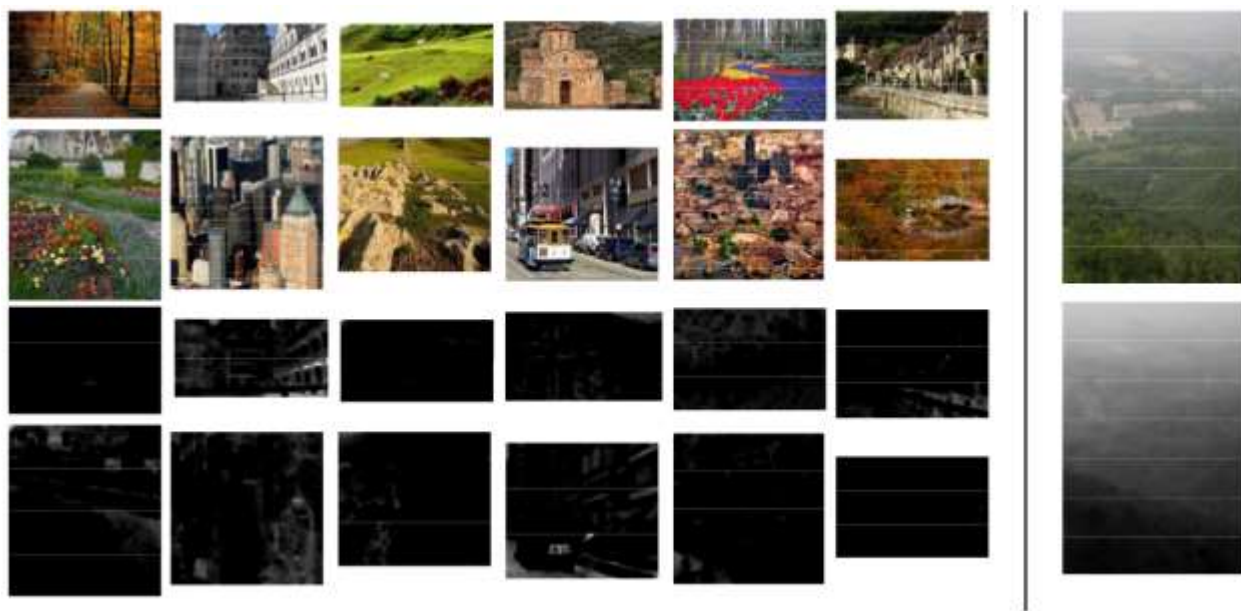
Jian Sun²

²Microsoft Research Asia

Xiaoou Tang^{1,3}

³Shenzhen Institute of Advanced Technology
Chinese Academy of Sciences

Dark channel



Haze-Free Image

Hazy Image

暗通道先验——对无雾室外图像观察到:

在大多数**非天空区域**中, 至少一个颜色通道在某些像素处的强度非常低


低亮度主要来源于三个原因:

1. 阴影
2. 彩色物体或者表面
3. 黑色物体或者表面


为什么暗通道先验成立?

——大自然是彩色的


Dark channel



强度直方图



累积直方图



暗通道平均强度

Statistics of the dark channels. (a) Histogram of the intensity of the pixels in all of the 5,000 dark channels (each bin stands for 16 intensity levels). (b) Cumulative distribution. (c) Histogram of the average intensity of each dark channel.

Dark channel



暗通道先验假设，在大多数非天空斑块中，无雾霾室外图像的至少一个颜色通道在某些像素处的强度非常低


图像的暗通道定义为：

$$J^{dk}(x) = \min_{c \in \{r, g, b\}} (\min_{y \in \Omega(x)} (J^c(y)))$$

其中 J^c 是 J 的颜色通道， $\Omega(x)$ 是以 x 为中心的局部图像块。

(1) 求解大气光 A

$$I(x) = J(x)T(x) + A(1 - T(x))$$



原：大气光 A 是从亮的像素估计的

使用**暗通道**来改进大气光估计 A ：

从观测图像的暗通道 I^{dark} 中选取最亮的前 **0.1%** 的点，
这些点对应到原图 I 中再去找**最亮的点**作为 A 的估计

(2) 求解传输图像 t

I



$$I(\mathbf{x}) = J(\mathbf{x})T(\mathbf{x}) + A(1 - T(\mathbf{x})) \quad (1)$$

假设 T 在局部 patch 内是恒定的, 即 $T(y) = T(x)$, $y \in \Omega(x)$ 有:

$$\min_{y \in \Omega(\mathbf{x})} (I^c(\mathbf{y})) = \tilde{t}(\mathbf{x}) \min_{y \in \Omega(\mathbf{x})} (J^c(\mathbf{y})) + (1 - \tilde{t}(\mathbf{x}))A^c \quad (6)$$


最小操作是在三个颜色通道上独立执行的, 这个方程等价于:

$$\min_{y \in \Omega(\mathbf{x})} \left(\frac{I^c(\mathbf{y})}{A^c} \right) = \tilde{t}(\mathbf{x}) \min_{y \in \Omega(\mathbf{x})} \left(\frac{J^c(\mathbf{y})}{A^c} \right) + (1 - \tilde{t}(\mathbf{x})) \quad (7)$$

在上述方程上取三个颜色通道之间的最小运算, 得到:

$$\min_c \left(\min_{y \in \Omega(\mathbf{x})} \left(\frac{I^c(\mathbf{y})}{A^c} \right) \right) = \tilde{t}(\mathbf{x}) \min_c \left(\min_{y \in \Omega(\mathbf{x})} \left(\frac{J^c(\mathbf{y})}{A^c} \right) \right) + (1 - \tilde{t}(\mathbf{x})) \quad (8)$$

T



(2) 求解传输图像 t



I

$$\min_c \left(\min_{\mathbf{y} \in \Omega(\mathbf{x})} \left(\frac{I^c(\mathbf{y})}{A^c} \right) \right) = \tilde{t}(\mathbf{x}) \min_c \left(\min_{\mathbf{y} \in \Omega(\mathbf{x})} \left(\frac{J^c(\mathbf{y})}{A^c} \right) \right) + (1 - \tilde{t}(\mathbf{x})) \quad (8)$$

根据暗通道先验，无雾图像 J 的暗通道 J^{dark} 趋于零：

略为粗暴

$$J^{dark}(\mathbf{x}) = \min_c \left(\min_{\mathbf{y} \in \Omega(\mathbf{x})} (J^c(\mathbf{y})) \right) = 0 \quad (9)$$

由于 A^c 始终为正：

$$\min_c \left(\min_{\mathbf{y} \in \Omega(\mathbf{x})} \left(\frac{J^c(\mathbf{y})}{A^c} \right) \right) = 0 \quad (10)$$

将式 (10) 代入式 (8)，可以简单地估计传输 \tilde{t} ：

$$\tilde{t}(\mathbf{x}) = 1 - \min_c \left(\min_{\mathbf{y} \in \Omega(\mathbf{x})} \left(\frac{I^c(\mathbf{y})}{A^c} \right) \right) \quad (11)$$



T

(2) 求解传输图像 t



$$\tilde{t}(\mathbf{x}) = 1 - \min_c \left(\min_{\mathbf{y} \in \Omega(\mathbf{x})} \left(\frac{I^c(\mathbf{y})}{A^c} \right) \right) \quad (11)$$

根据暗通道先验，传输可估计为：

$$\tilde{t}(\mathbf{x}) = 1 - \omega \min_c \left(\min_{\mathbf{y} \in \Omega(\mathbf{x})} \left(\frac{I^c(\mathbf{y})}{A^c} \right) \right)$$

- $\frac{I^c(\mathbf{y})}{A^c}$ 是归一化后的像素强度
- A^c 是该通道的大气光强度
- 引入常数参数 ω 来选择性地为远处对象保留非常少量的雾霾



refined transmission map
after soft matting

(3) 求解去雾图像 J



I



J

根据前面, 已知 I, A, t , 根据雾天退化模型:

$$I = t \cdot J + (1 - t) \cdot A$$

得到去雾图像

$$J = \frac{I - A}{t} + A$$

$$\mathbf{J}(\mathbf{x}) = \frac{\mathbf{I}(\mathbf{x}) - \mathbf{A}}{\max(t(\mathbf{x}), t_0)} + \mathbf{A}$$

Limitation



I



J



T



Proximal Dehaze-Net: A Prior Learning-Based Deep Network for Single Image Dehazing

Dong Yang and Jian Sun

Xi'an Jiaotong University, Xi'an, 710049, China



03

Dehazing energy model



Motivation



1. 传统方法：先验主要基于人类观察，并不总是适用于不同的现实世界图像
2. 基于学习的方法：不考虑与雾霾相关的先验来约束映射空间

Method



DCP



Proximal
Dehaze-Net



步骤:

1. 将单幅图像去雾逆问题描述为**颜色和暗通道空间中雾霾成像约束**的能量模型，由暗通道和传输先验正则化。
2. 使用**半二次分裂 (HQS)** 的迭代优化算法，联合估计传输图 (T) 和潜在无雾图像 (J)
3. 通过使用卷积神经网络学习它们对应的**近端算子**来**隐式**学习传输和暗通道先验。

Dehazing energy model

$$I(x) = J(x)T(x) + A(1 - T(x)) \quad (1)$$

给定一个有雾图像 I ，设已知的全局大气光 A ，并划分 (1) 的两边，在每个颜色通道中的 A ：

$$\frac{I^c(x)}{A^c} = \frac{J^c(x)}{A^c} T(x) + (1 - T(x)), c \in \{r, g, b\} \quad (4)$$

用 P^c 表示 $\frac{I^c(x)}{A^c}$ ，用 Q^c 表示 $\frac{J^c(x)}{A^c}$ ， P, Q 分别表示缩放的有雾图像和潜在无雾图像

(4) 可以用简洁的形式重写，如下所示：

$$P^c = Q^c \circ T + (1 - T) \quad (5)$$

其中 \circ 是矩阵的元素乘积

(5) 描述了每个颜色通道上观测到的雾霾图像和理想中无雾图像之间的关系

Dehazing energy model

$$P^c = Q^c \circ T + (1 - T) \quad (5)$$

暗通道:

$$P^{dk}(x) = \min_{c \in \{r, g, b\}} \left(\min_{y \in \Omega(x)} P^c(y) \right)$$

假设 T 在局部 patch 内是恒定的, 即 $T(y) = T(x)$, $y \in \Omega(x)$, 计算暗通道

$$\begin{aligned} P^{dk}(x) &= \min_{c \in \{r, g, b\}} \left(\min_{y \in \Omega(x)} Q^c(y)T(y) + (1 - T(y)) \right) \\ &= \min_{c \in \{r, g, b\}} \left(\min_{y \in \Omega(x)} Q^c(y) \right) T(x) + (1 - T(x)) \\ &= Q^{dk}(x)T(x) + (1 - T(x)). \end{aligned}$$

$$P^{dk} = Q^{dk} \circ T + 1 - T \quad (6)$$

其中 P^{dk} , Q^{dk} 是 P , Q 的暗通道

Dehazing energy model

将等式 (5) 在颜色空间和等式 (6) 在暗通道空间中作为损失项，设计了一个**去雾能量函数**：

$$E(Q, T) = \frac{\alpha}{2} \sum_{c \in \{r, g, b\}} \|Q^c \circ T + 1 - T - P^c\|_F^2 + \frac{\beta}{2} \|Q^{dk} \circ T + 1 - T - P^{dk}\|_F^2 + f(T) + g(Q^{dk}) \quad (7)$$

其中 α 和 β 是数据项的系数

$f(T)$ 和 $g(Q^{dk})$ 是正则化项，用于对传输图 T 和暗通道 Q^{dk} 的先验进行建模

通过求解以下优化问题，可以得到无雾图像 Q 和传输图 T ：

$$\{Q^*, T^*\} = \arg \min_{Q, T} E(Q, T) \quad (8)$$

Model optimization

$$E(Q, T) = \frac{\alpha}{2} \sum_{c \in \{r, g, b\}} \|Q^c \circ T + 1 - T - P^c\|_F^2 + \frac{\beta}{2} \|Q^{dk} \circ T + 1 - T - P^{dk}\|_F^2 + f(T) + g(Q^{dk}) \quad (7)$$

对等式 (8) 使用**半二次分裂 (HQS)** 算法:

通过引入辅助变量 U 代替潜在无雾图像的暗通道 Q^{dk} , 推导出增强能量函数:

$$E(Q, T, U) = \frac{\alpha}{2} \sum_{c \in \{r, g, b\}} \|Q^c \circ T + 1 - T - P^c\|_F^2 + \frac{\beta}{2} \|U \circ T + 1 - T - P^{dk}\|_F^2 + \frac{\gamma}{2} \|U - Q^{dk}\|_F^2 + f(T) + g(U), \quad (9)$$

其中 γ 是惩罚权重, 当 $\gamma \rightarrow \infty$ 时, 最小化 Eqn (9) 的解, 收敛到最小化 Eqn (7)
初始化 $Q_0 = P$, T_0 的所有元素都是 1

Model optimization

$$E(Q, T, U) = \frac{\alpha}{2} \sum_{c \in \{r, g, b\}} \|Q^c \circ T + 1 - T - P^c\|_F^2 + \frac{\beta}{2} \|U \circ T + 1 - T - P^{dk}\|_F^2 + \frac{\gamma}{2} \|U - Q^{dk}\|_F^2 + f(T) + g(U), \quad (9)$$

对于 HQS 算法的迭代 n ，最小化 Eqn(9) 可以通过解决三个子问题来交替更新 U 、 T 和 Q 来实现

$$U_n = \arg \min_U \frac{\beta}{2} \|T_{n-1} \circ U - (P^{dk} + T_{n-1} - 1)\|_F^2 + \frac{\gamma}{2} \|U - Q^{dk}_{n-1}\|_F^2 + g(U),$$

$$T_n = \arg \min_T \frac{\alpha}{2} \sum_c \|Q_{n-1}^c \circ T - (P^c + T - 1)\|_F^2 + \frac{\beta}{2} \|U_n \circ T - (P^{dk} + T - 1)\|_F^2 + f(T),$$

$$Q_n = \arg \min_Q \frac{\alpha}{2} \sum \|T_n \circ Q^c - (P^c + T_n - 1)\|_F^2 + \frac{\gamma}{2} \|Q^{dk} - U_n\|_F^2.$$

Model optimization

Update U :给定迭代 $n-1$ 时估计的无雾图像 Q_{n-1} 和传输映射 T_{n-1} , **辅助变量 U** 可更新为:

$$U_n = \arg \min_U \frac{\beta}{2} \| U \circ T_{n-1} + 1 - T_{n-1} - P^{dk} \|_F^2 + \frac{\gamma}{2} \| U - Q_{n-1}^{dk} \|_F^2 + g(U) \quad (10)$$

利用近端算子推导出:

$$U_n = \text{prox}_{\frac{1}{b_n}g}(\hat{U}_n) \quad (11)$$

$$\hat{U}_n = \frac{1}{b_n} [\beta T_{n-1} \circ (P^{dk} + T_{n-1} - 1) + \gamma Q_{n-1}^{dk}], \quad (12)$$

Model optimization

Update T : 接下来更新传输图 T, 给定 Q_{n-1} 和 U_n ,

$$T_n = \arg \min_T \frac{\alpha}{2} \sum_c \| Q_{n-1}^c \circ T + 1 - T - P^c \|_F^2 + \frac{\beta}{2} \| U_n \circ T + 1 - T - P^{dk} \|_F^2 + f(T). \quad (14)$$

然后利用近端算子推导:

$$T_n = \text{prox}_{\frac{1}{c_n}f}(\hat{T}_n) \quad (15)$$

$$\hat{T}_n = \frac{1}{c_n} \left[\sum_c \alpha (Q_{n-1}^c - 1) \circ (P^c - 1) + \beta (U_n - 1) \circ (P^{dk} - 1) \right] \quad (16)$$

$$c_n = \sum_c \alpha (Q_{n-1}^c - 1) \circ (Q_{n-1}^c - 1) + \beta (U_n - 1) \circ (U_n - 1)$$

Model optimization

Update Q : 给定 T_n 和 U_n , 无雾图像 Q 更新为:

$$Q_n = \arg \min_Q \frac{\alpha}{2} \sum_c \| Q^c \circ T_n + 1 - T_n - P^c \|_F^2 + \frac{\gamma}{2} \| Q^{dk} - U_n \|_F^2 \quad (17)$$

等式(17) 可以改写为:

$$\vec{Q}_n = \arg \min_{\vec{Q}} \frac{\alpha}{2} \| \vec{Q} \circ \vec{T}_n + 1 - \vec{T}_n - \vec{P} \|_2^2 + \frac{\gamma}{2} \| D\vec{Q} - \vec{U}_n \|_2^2 \quad (18)$$

解决方案:

$$\vec{Q}_n = \frac{\alpha(\vec{P} + \vec{T}_n - 1) \circ \vec{T}_n + \gamma D^T \vec{U}_n}{\alpha \vec{T}_n \circ \vec{T}_n + \gamma \text{diag}(D^T D)} \quad (19)$$

计算暗通道是从每个像素周围的局部颜色补丁中提取最小值。

该操作可以由矩阵 D 一个表示提取的最小值的位置, 来实现, 即 $\overrightarrow{Q^{dk}} = D\vec{Q}$, 其中 \vec{Q} 是矢量化 Q

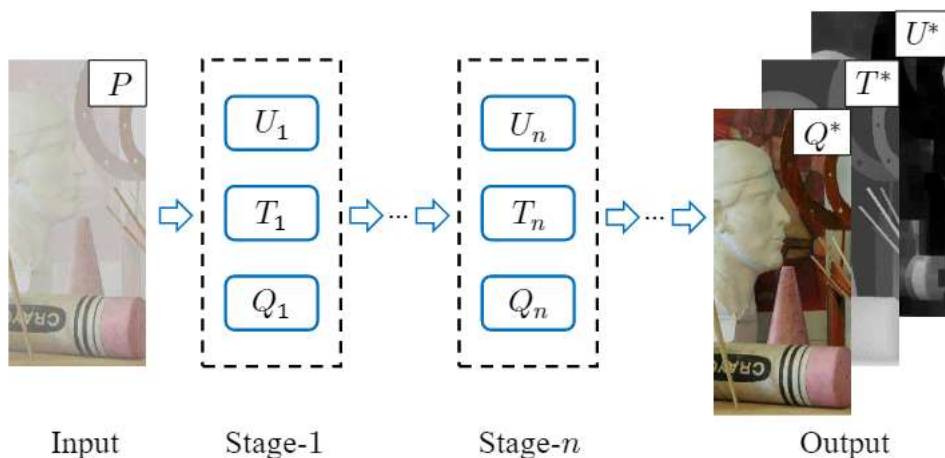
更新后的无雾图像 Q_n 可以通过将 \vec{Q}_n 重塑为与输入图像相同大小的矩阵来导出

04

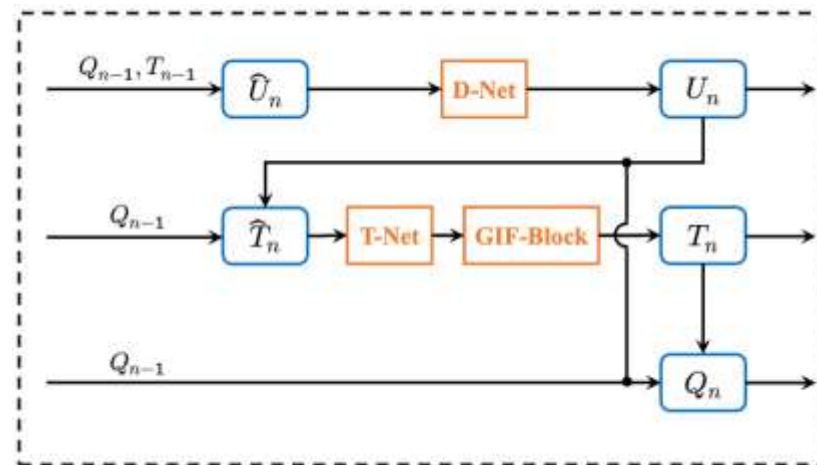
Proximal Dehaze-Net



Proximal Dehaze-Net



Multi-stage network for image dehazing



Network structure for the n -th stage

使用深度 CNN 来学习它们对应的近端算子 $\text{prox}_{\frac{1}{b_n}g}$ 和 $\text{prox}_{\frac{1}{c_n}f}$ 来更新每个阶段的 U_n 和 T_n :

$$U_n = \text{prox}_{\frac{1}{b_n}g}(\hat{U}_n) \triangleq \mathcal{G}(\hat{U}_n) \quad (22)$$

$$T_n = \text{prox}_{\frac{1}{c_n}f}(\hat{T}_n) \triangleq \mathcal{F}(\hat{T}_n)$$

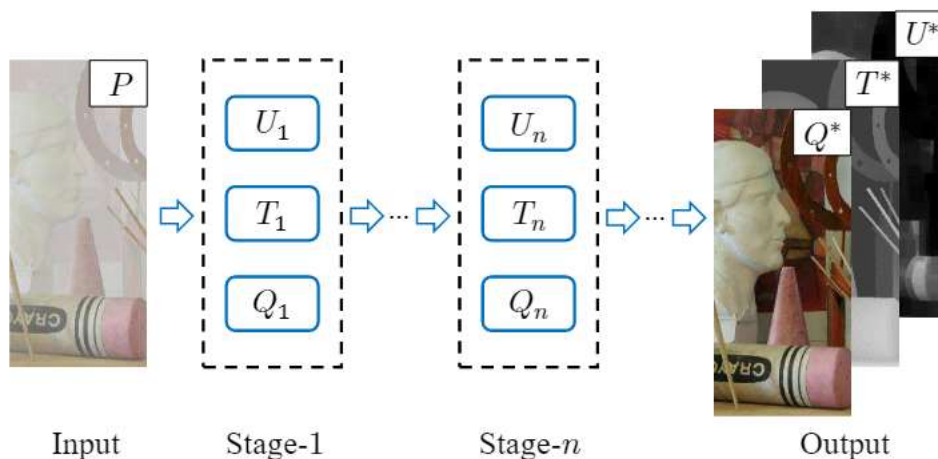
$$U_n = \mathcal{G}(\hat{U}_n) \triangleq \text{D-Net}(\hat{U}_n, P) \quad (23)$$

$$T_n = \mathcal{F}(\hat{T}_n) \triangleq \text{GIF-Block}(\text{T-Net}(\hat{T}_n, P)) \quad (24)$$

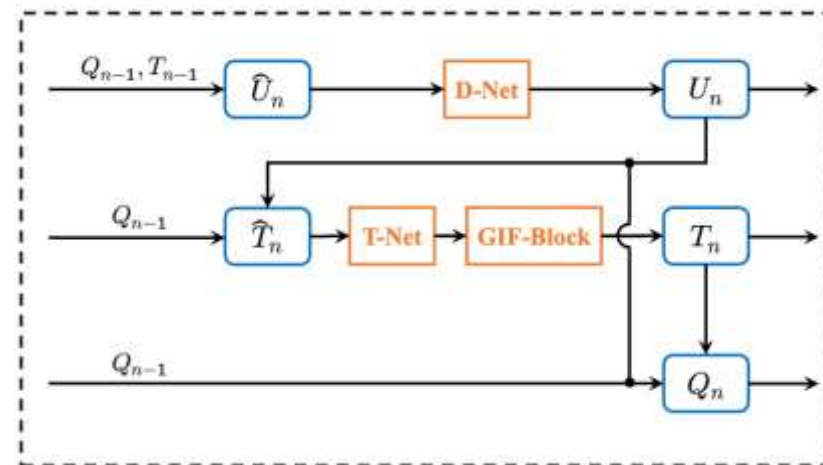
其中 \mathcal{G} 和 \mathcal{F} 是要学习的深度 CNN 来表示相应的近端算子

P : 有雾图像, 与 \hat{U}_n 一起 Concat 作为输入

Network design



Multi-stage network for image dehazing



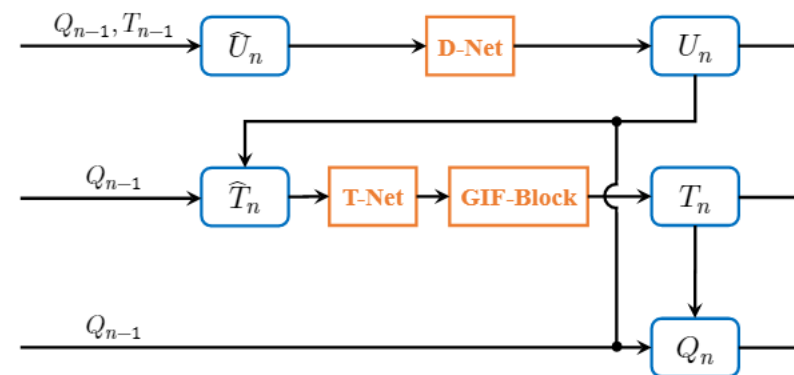
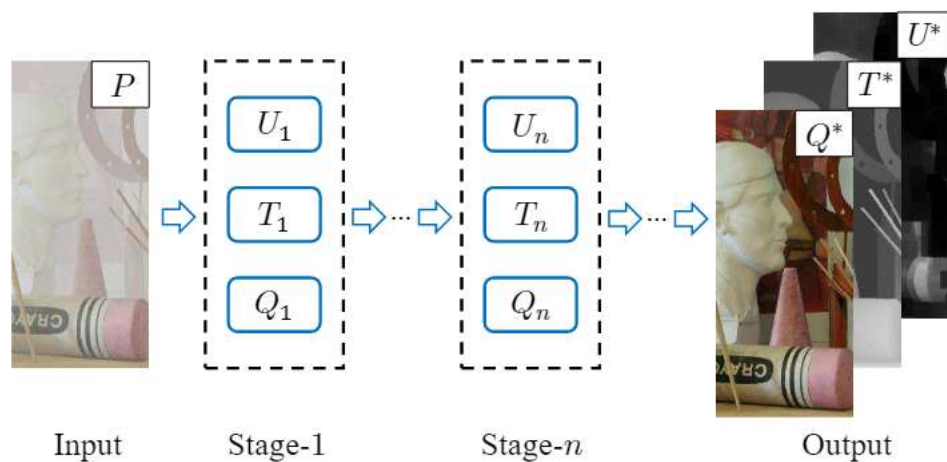
Network structure for the n -th stage

D-Net 和 T-Net 具有相似的结构：

包括三个级联卷积块（每个块由一个卷积层、一个 ReLU 层、一个池化层和一个上采样层组成）。
这些块中的卷积层分别有 9 个 7×7 滤波器、9 个 5×5 滤波器和 9 个 3×3 滤波器
最后一个块后面是另一个带有一个 1×1 过滤器的卷积层
然后将输出图最终发送到 D-Net 的 ReLU 层或 T-Net 的 sigmoid 层


ReLU 层旨在保持输出暗通道 U 非负，而 sigmoid 层是将输出传输图 T 保持在 $[0, 1]$ 内

Network design

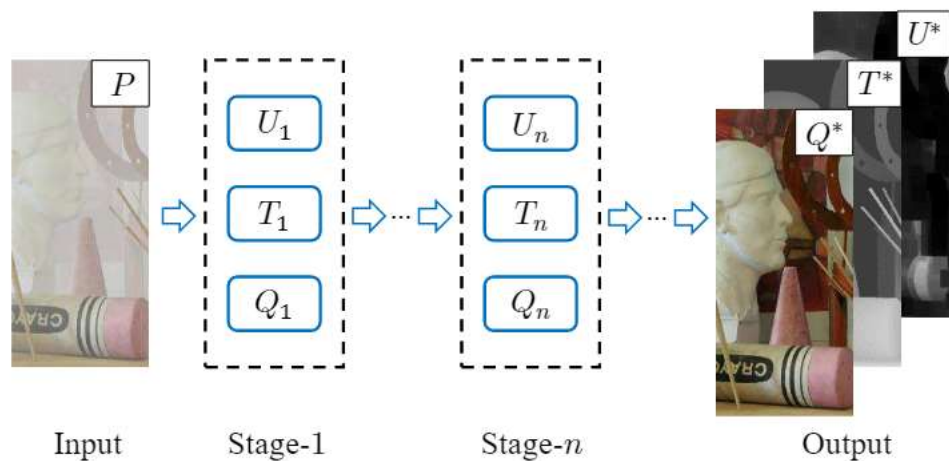


GIF-Block 以输入图像 P 为指导，执行引导图像过滤 T-Net 的输出

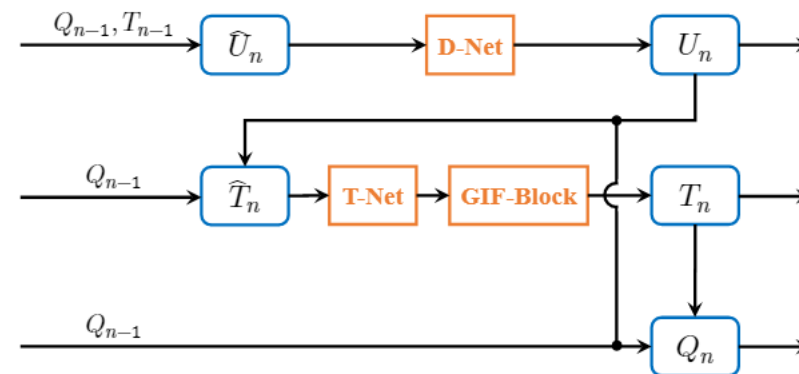
$$\text{GIF-Block}(\text{T-Net}(\hat{T}_n, P)) \triangleq \text{GIF}_P(\text{T-Net}(\hat{T}_n, P)) \quad (25)$$



Network design



$$\hat{U}_n = \frac{1}{b_n} [\beta T_{n-1} \circ (P^{dk} + T_{n-1} - 1) + \gamma Q_{n-1}^{dk}]$$

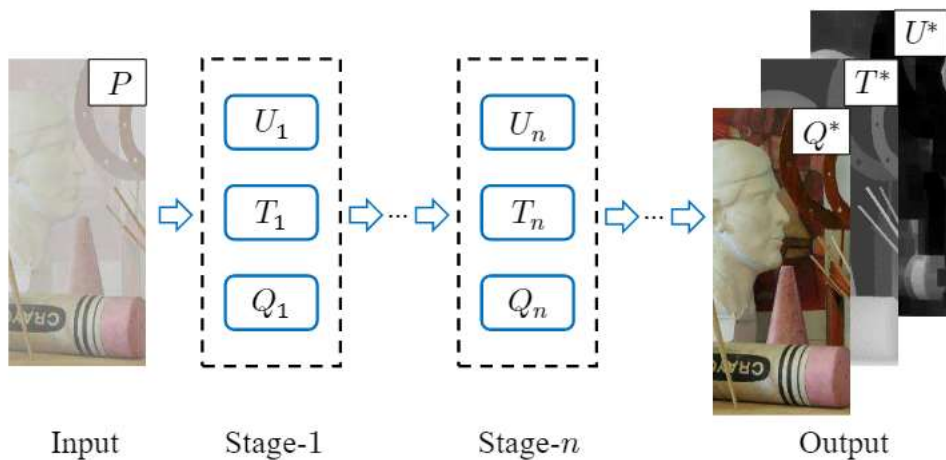


对于第 n 阶段, U_n 首先由 Eqn(12) 计算进入卷积神经网络, 即 D-Net, 执行近端映射 $\text{prox}_{\frac{1}{b_n}g}$, 更新后的暗通道为:

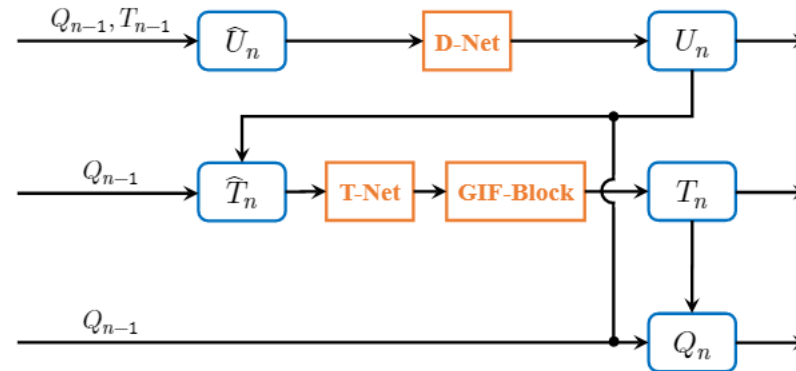
$$U_n = \mathcal{G}(\hat{U}_n) \triangleq \text{D-Net}(\hat{U}_n, P)$$

其中将 U_n 与模糊图像 P 连接起来作为输入。

Network design



$$\hat{T}_n = \frac{1}{c_n} \left[\sum_c \alpha (Q_{n-1}^c - 1) \circ (P^c - 1) + \beta (U_n - 1) \circ (P^{dk} - 1) \right]$$




类似地， \hat{T}_n 首先使用 Eqn(16) 计算，然后与 P 连接并发送到另一个卷积神经网络 T-Net 和 GIF-Block 以执行近端映射，更新后的传输图为：

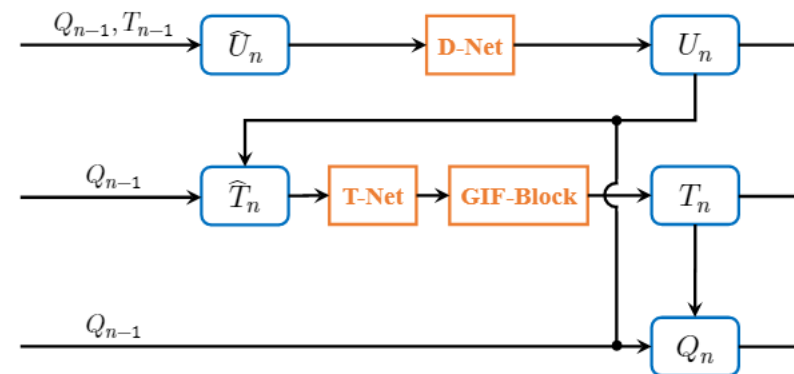
$$T_n = \mathcal{F}(\hat{T}_n) \triangleq \text{GIF-Block}(\text{T-Net}(\hat{T}_n, P)) \quad (24)$$

T-Net 和 GIF-Block 分别负责传输估计和引导图像滤波(GIF)，以更好地与图像边缘对齐

Network design



$$\vec{Q}_n = \frac{\alpha(\vec{P} + \vec{T}_n - 1) \circ \vec{T}_n + \gamma D^\top \vec{U}_n}{\alpha \vec{T}_n \circ \vec{T}_n + \gamma \text{diag}(D^\top D)}$$



最后, Q_{n-1} 、 U_n 和 T_n , 使用 Eqn(19) 获得更新的 Q_n 。

在 N stages 之后, 最终估计的无雾图像 J 的通道为

$$J^c = Q_N^c A^c \text{ for } c \in \{r, g, b\}$$


Network training



(a) Input



(b) $U = \mathcal{G}(\hat{U})$



(c) $T = \mathcal{F}(\hat{T})$



(d) Output

$$\ell = \sum_{o \in \{Q, T, U\}} \sum_{\mathbf{x}} \|O^*(\mathbf{x}) - O^{\text{gt}}(\mathbf{x})\|_1 \quad (26)$$

Results



(a) Input



(b) Result of DCP



(c) Result of Ener- L_1



(d) Result of proximal dehaze-net



(a) Underwater image enhancement



(b) Anti-halation enhancement



(c) Haze-free image



Limitations



Heavy haze image dehazing



Night-time image dehazing



THANKS